

Stacjonarność

ASC 2023

Piotr Żoch

- Regresja pozorną.
- Funkcje ACF i PCF.
- Badanie stacjonarności: testy DF, ADF, KPSS.

Sprawy organizacyjne

- **Regresja pozorna (*spurious regression*):** zmienne (x_t, y_t) nie mają ze sobą żadnego związku, ale uzyskujemy statystycznie istotnych oszacowania
- Klasyczny przykład: regresja jednej zmiennej niestacjonarnej na drugą, obie to błędzenie losowe.

$$x_t = x_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma_\varepsilon^2)$$

$$y_t = y_{t-1} + \nu_t, \quad \nu_t \sim N(0, \sigma_\nu^2)$$

$$y_t = \beta x_t + e_t$$

- Objawy regresji pozornej:
 - Wysoka wartość statystyki testowej (*p-value* niskie).
 - Wysokie R^2 .
 - Silna autokorelacja reszt.
 - Zmiana wyniku po dodatniu opóźnionej zmiennej objaśniającej (brak statystycznej istotności).

- Dlaczego tak się dzieje?
- Problem:
 - Rozkłady statystyk testowych są niestandardowe (czyli błędem jest badanie istotności zmiennych przy założeniu normalności rozkładu statystyki).
- Estymator OLS nie jest zgodny.
 - nie będzie zbiegać do 0 (prawdziwej wartości w przykładzie powyżej) przy zwiększeniu liczby obserwacji.

Regresja pozorną: przykład

- Przykład: błędzenie losowe z dryfem

$$x_t = \mu_x + x_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma_\varepsilon^2)$$

$$y_t = \mu_y + y_{t-1} + \nu_t, \quad \nu_t \sim N(0, \sigma_\nu^2)$$

- Zauważmy, że

$$x_t = \mu_x t + \sum_{k=1}^t \varepsilon_k + x_0$$

$$y_t = \mu_y t + \sum_{k=1}^t \nu_k + y_0$$

Regresja pozorną: przykład

- Mamy

$$\hat{\beta} = \frac{\sum_{t=1}^T x_t y_t}{\sum_{t=1}^T x_t^2} = \frac{\sum_{t=1}^T \left(\mu_x t + \sum_{k=1}^t \epsilon_k + x_0 \right) \left(\mu_y t + \sum_{k=1}^t \nu_k + y_0 \right)}{\sum_{t=1}^T \left(\mu_x t + \sum_{k=1}^t \epsilon_k + x_0 \right)^2}$$

- Aby to uprościć, użyjemy

$$\frac{1}{T^2} \sum_{t=1}^T t \rightarrow \frac{1}{2}$$

$$\frac{1}{T^3} \sum_{t=1}^T t^2 \rightarrow \frac{1}{3}$$

Regresja pozorna: przykład

- Mamy

$$\hat{\beta} = \frac{\frac{1}{T^3} \sum_{t=1}^T \left(\mu_x t + \sum_{k=1}^t \epsilon_k + x_0 \right) \left(\mu_y t + \sum_{k=1}^t \nu_k + y_0 \right)}{\frac{1}{T^3} \sum_{t=1}^T \left(\mu_x t + \sum_{k=1}^t \epsilon_k + x_0 \right)^2}$$
$$\xrightarrow{p} \frac{\mu_y}{\mu_x}$$

- *Uwaga:* w tym przykładzie za regresję pozorną odpowiadały wyrazy zawierające t^2 czyli trend deterministyczny – podobne problemy będziemy mieli przy zmiennych trendostacjonarnych.
- *Uwaga:* podobne problemy występują też w przypadku błędzenia losowego, ale trochę trudniej to pokazać analitycznie.

Funkcje ACF i PACF

- **Funkcja autokorelacji** (*Autocorrelation Function*) to współczynnik korelacji między dwiema realizacjami

$$\rho_k = \frac{\text{Cov}(y_t, y_{t-k})}{\text{Var}(y_t)}$$

i $\rho_k \in [-1, 1]$.

- Użyliśmy $\sqrt{\text{Var}(y_t) \text{Var}(y_{t-k})} = \text{Var}(y_t)$ (to wymaga stacjonarności).

- **Funkcja autokorelacji cząstkowej** (*Partial Autocorrelation Function*) to współczynnik korelacji między dwiema realizacjami oddalonymi od siebie o k okresów **bez** uwzględnienia wpływu wszystkich obserwacji “pomiędzy”.
- Funkcja ta jest równa wyestymowanemu współczynnikowi α_k w modelu autoregresyjnym k -tego rzędu

$$y_t = \mu + \alpha_1 y_{t-1} + \dots + \alpha_k y_{t-k} + \varepsilon_t$$

- Służy do badania autokorelacji reszt z regresji liniowej

$$y_t = \beta_0 + \beta_1 x_{1,t} + \dots + \beta_n x_{n,t} + e_t$$

$$e_t = \rho_1 e_{t-1} + \rho_2 e_{t-2} + \dots + \rho_k e_{t-k} + \varepsilon_t$$

- Wartość statystyki testowej nR^2 , gdzie R^2 jest z regresji pomocniczej

$$\hat{e}_t = \alpha_0 + \sum_{j=1}^n \alpha_j x_{j,t} + \sum_{i=1}^k \rho_i \hat{e}_{t-i} + \varepsilon_t$$

- $H_0: \rho_1 = \rho_2 = \dots = \rho_k = 0$. Rozkład to $nR^2 \sim \chi_k^2$

$$Q = T(T+2) \sum_{i=1}^k \frac{\hat{\rho}_i^2}{T-i}$$
$$\sim \chi_k^2$$

- H_0 : proces jest białym szumem
- Test wykorzystywany przede wszystkim do badania autokorelacji reszt.
- Maddala (2001): test obciążony w kierunku H_0 , niska moc. Breusch-Godfrey preferowany.

Badanie stacjonarności

- Najpopularniejszy sposób badania stacjonarności zmiennych.
- Model:

$$y_t = \beta y_{t-1} + \varepsilon_t$$
$$\varepsilon_t \sim iid(0, \sigma^2)$$

- H_0 : proces jest błędzeniem losowym ($\beta = 1$) - niestacjonarność
- H_1 : proces jest procesem AR(1) ($|\beta| < 1$) - stacjonarność

Test Dickey-Fullera

- Model:

$$y_t = \beta y_{t-1} + \varepsilon_t$$

$$\varepsilon_t \sim iid(0, \sigma^2)$$

- Odejmując y_{t-1} od obu stron

$$\Delta y_t = (\beta - 1) y_{t-1} + \varepsilon_t$$

$$\Delta y_t = \rho y_{t-1} + \varepsilon_t$$

- $H_0 : \rho = 0$ - niestacjonarność
- $H_1 : \rho \in (-2, 0)$ - stacjonarność

- **UWAGA:** nie możemy po prostu zastosować OLS i za pomocą statystyki t zbadać istotność w standardowy sposób.
 - H_0 : niestacjonarność. Rozkłady statystyk są niestandardowe!
- Wykorzystujemy specjalne tablice z wartościami krytycznymi dla testu DF.
- Uwaga techniczna: wielkości krytyczne rozkładu statystyki DF są zawsze ujemne.

- Procedura:
 - Regresja Δy_t na y_{t-1} .
 - Porównujemy statystykę t z wartościami krytycznymi testu DF:
 - t **poniżej** wartości krytycznej: odrzucamy H_0 (stacjonarność?)
 - t **powyżej** wartości krytycznej: nie odrzucamy H_0 (niestacjonarność?)

- Błądzenie losowe z dryfem

$$y_t = \alpha_1 + \beta y_{t-1} + \varepsilon_t$$

- Trend deterministyczny

$$y_t = \alpha_1 + \alpha_2 t + \beta y_{t-1} + \varepsilon_t$$

- We wszystkich powyższych przypadkach H_0 to też niestacjonarność.

Rozszerzony test DF (ADF)

- Reszty z regresji

$$\Delta y_t = \rho y_{t-1} + \varepsilon_t$$

często wykazują silną autokorelację.

- Rozszerzony test DF (augmented DF)

$$\Delta y_t = \rho y_{t-1} + \sum_{i=1}^k \gamma_i \Delta y_{t-i} + \varepsilon_t$$

gdzie k jest dobrane tak, żeby wyeliminować autokorelację reszt.

- Procedura:
 - Regresja Δy_t na y_{t-1} .
 - Sprawdzamy autokorelację reszt (test Breuscha-Godfrey, nie Durbina-Watsona).
 - Jeśli jest, dodajemy opóźnioną różnicę Δy_{t-2} do specyfikacji i powtarzamy.
 - W przeciwnym wypadku:
 - t **poniżej** wartości krytycznej: odrzucamy H_0 (stacjonarność?)
 - t **powyżej** wartości krytycznej: nie odrzucamy H_0 (niestacjonarność?)

- Reszty z regresji

$$\Delta y_t = \rho y_{t-1} + \varepsilon_t$$

często wykazują silną autokorelację.

- Rozszerzony test DF (augmented DF)

$$\Delta y_t = \rho y_{t-1} + \sum_{i=1}^k \gamma_i \Delta y_{t-i} + \varepsilon_t$$

gdzie k jest dobrane tak, żeby wyeliminować autokorelację reszt.

- Model:

$$y_t = x_t + z_t$$

$$x_t = x_{t-1} + v_t$$

$$z_t = \mu_0 + \varepsilon_t$$

$$\varepsilon_t \sim iid(0, \sigma_\varepsilon^2)$$

$$v_t \sim iid(0, \sigma_v^2)$$

- $H_0 : \sigma_v^2 = 0$ - stacjonarność
- $H_1 : \sigma_v^2 > 0$ - niestacjonarność

- Procedura:
 - Regresja y_t na stałą (+ ew. trend deterministyczny).
 - Obliczyć sumy $S_t = \sum_{j=1}^t e_j$ dla $t = 1, 2, 3, \dots, T$, gdzie e_j to reszty z regresji powyżej.
 - Statystyka testowa: $KPSS = \frac{1}{T^2} \frac{\sum_{t=1}^T S_t^2}{\hat{\sigma}^2}$ gdzie $\hat{\sigma}^2$ to długookresowa wariancja reszt.

Testowanie (nie)stacjonarności

- W przypadku małej próby i procesów o wysokim stopniu persystencji:
 - Test ADF: niska moc.
 - Test KPSS: zaburzenia rozmiaru.
- Przykład: jak odróżnić proces trendostacjonarny

$$y_t = \alpha t + \epsilon_t$$

od błędzenia losowego z dryfem

$$\begin{aligned} y_t &= \mu + y_{t-1} + \epsilon_t \\ &= y_0 + \mu t + \sum_{i=0}^t \epsilon_{t-i} \end{aligned}$$

- Czy to, czy proces jest stacjonarny czy niestacjonarny, ma znaczenie?
- Teoria ekonomii może być bardziej pomocna od testów statystycznych...

- Jaki test wybrać? Jakie deterministyczne regresory uwzględnić?
- Problem:
 - dodatkowe deterministyczne komponenty w regresji, które są nieobecne w procesie generującym dane, redukują stopnie swobody i obniżają moc testu stacjonarności.
 - pominięcie deterministycznych komponentów w regresji, które są obecne w procesie generującym dane, obniża moc testu.

Figure 4.7 A procedure to test for unit roots.

Estimate $\Delta y_t = a_0 + \gamma y_{t-1} + a_2 t + \sum \beta_i \Delta y_{t-i} + \varepsilon_t$

