

# Modele wektorowej autoregresji

ASC 2023

---

Piotr Żoch

- Model VAR
- Budowa i analiza modelu VAR
- Prognozowanie za pomocą modelu VAR
- Modele SVAR

## Modele VAR

---

- VAR: **v**ector **a**utoregression
- uwzględnia powiązania między zmiennymi ekonomicznymi
- pomocny w opisie dynamicznych właściwości zmiennej wielowymiarowej
- przy dodatkowych założeniach - model ekonomiczny (structural VAR - SVAR)

- Modele VAR powstały w późnych latach 70. w odpowiedzi na problemy dużych modeli strukturalnych:
  - podział na zmienne endo- i egzogeniczne a priori
  - wybór struktury dynamicznej modelu a priori
  - niska jakość prognoz
  - problemy z identyfikacją

- Sims (1980), modele VAR przydatne w:
  - prognozowaniu szeregów czasowych
  - projektowaniu i ewaluacji modeli ekonomicznych
  - ocenie efektów alternatywnych polityk (jeśli nie różnią się zbytnio od obecnych)

- Niech  $y_t$  będzie wektorem  $y_t = (y_{1,t}, y_{2,t}, \dots, y_{n,t})'$ . Model VAR to

$$y_t = A_0 + A_1 y_{t-1} + A_2 y_{t-2} + \dots + A_p y_{t-p} + \epsilon_t$$

gdzie  $\epsilon_t \sim N(0, \Sigma)$ .

- $A_0$  to wektor  $n \times 1$ ,  $A_1, \dots, A_p$  oraz  $\Sigma$  to macierze o wymiarach  $n \times n$ .
- Można też dodać zmienne deterministyczne, np. trend, zmienne 0/1, zmienne sezonowe i tym podobne.

- Model VAR można też przedstawić za pomocą wielomianu opóźnień jako

$$(I - A_1L - \dots - A_pL^p)y_t = A_0 + \epsilon_t$$

czyli

$$A(L)y_t = A_0 + \epsilon_t.$$



- Brak podziału a priori na zmienne endo- i egzogeniczne
- Ateoretyczność (teoria służy do wybrania zmiennych, nie do modelowania zależności między nimi)
- Zwykle bardzo dobre prognozy w krótkim okresie
- Parametry modelu *nie* podlegają interpretacji, zamiast tego interesuje nas np. funkcja reakcji na impuls

- Dwie decyzje przy budowie modelu VAR:
  - jakie zmienne uwzględnić (+ zmienne deterministyczne)
  - jaki rząd opóźnień wybrać

- Kryteria:
  - kryteria informacyjne (AIC, BIC, HQIC)
    - dopasowanie do danych vs. liczba oszacowanych parametrów
  - brak autokorelacji składnika losowego
  - test istotności opóźnień

- W przypadku modelu AR(p) mieliśmy

$$(1 - a_1L - a_2L^2 - \dots - a_pL^p) y_t = a_0 + \epsilon_t$$

$$A(L) y_t = a_0 + \epsilon_t$$

- Model AR(p) jest **stacjonarny** tylko dla wartości parametrów  $a_1, \dots, a_p$ , dla których pierwiastki równania  $A(x)$  spełniają  $|x_p| > 1$  dla każdego  $p$
- Analogicznie jest w przypadku modelu VAR(p)

- Jeśli  $\lim_{k \rightarrow \infty} \frac{\partial y_{t+k}}{\partial \epsilon_t} = 0$  to model VAR jest *stacjonarny*
  - wpływ szoku w okresie  $t$  wygasa w przyszłości
    - istnieje poziom  $\mu$ , do którego proces powraca
    - tempo powrotu dane przez pierwiastki równania

$$|A(z)| = 0$$

- jeśli pierwiastki są poza kołem jednostkowym - stacjonarność

- Przykład: VAR(1)

$$y_t = A_1 y_{t-1} + \epsilon_t$$
$$\underbrace{(I - A_1 L)}_{=A} y_t = \epsilon_t$$

czyli

$$A = \begin{bmatrix} 1 - a_{11}L & -a_{12}L \\ -a_{21}L & 1 - a_{22}L \end{bmatrix}$$

i

$$|A(z)| = (1 - a_{11}z)(1 - a_{22}z) - a_{11}a_{21}z^2$$

- Przykład: VAR(1). Niech  $a_{11} = a_{22} = \rho$  a  $a_{12} = a_{21} = 0$ .

$$|A(z)| = (1 - \rho z)(1 - \rho z)$$

więc  $z = \rho^{-1}$  a zatem pierwiastki będą poza kołem jednostkowym dla  $-1 < \rho < 1$ .

## VAR - stacjonarność

- Co w przypadku VAR(p), gdzie  $p > 1$ ?
- Każdy VAR(p) można przekształcić do VAR(1) (*postać kanoniczna*)
- Przykład: AR(2)

$$y_{1,t} = \rho_1 y_{1,t-1} + \rho_2 y_{1,t-2} + \epsilon_t$$

Zdefiniujmy  $y_{2,t} = y_{1,t-1}$ . Mamy układ równań

$$y_{1,t} = \rho_1 y_{1,t-1} + \rho_2 y_{2,t-1} + \epsilon_t$$

$$y_{2,t} = y_{1,t-1}$$

czyli

$$y_t = \underbrace{\begin{bmatrix} \rho_1 & \rho_2 \\ 1 & 0 \end{bmatrix}}_{A_1} y_{t-1} + \begin{bmatrix} 1 \\ 0 \end{bmatrix} \epsilon_t$$



- Dla VAR(1)

$$|A(z)| = |I - A_1 z|$$

więc jeśli mamy z, że  $|I - A_1 z| = 0$  to

$$|I \frac{1}{z} - A_1| = 0$$

czyli

$$|A_1 - I \underbrace{\lambda}_{=\frac{1}{z}}| = 0$$

- VAR(1) jest stacjonarny, jeśli wszystkie pierwiastki  $\lambda$  równania

$$|A_1 - I\lambda| = 0$$

leżą w kole jednostkowym.

- $\lambda$  to wartości własne macierzy  $A_1$
- Uwaga: łatwo się pomylić czy pierwiastki/wartości własne mają być w czy *poza* kołem jednostkowym (podobnie jak w przypadku modeli AR)

- Estymacja: można zastosować metodę najmniejszych kwadratów (KMNK/OLS) dla każdego równania osobno
- Co zrobić jeśli poszczególne zmienne są niestacjonarne?
  - uwzględnić informację o kointegracji (jeśli jest) - model VECM
  - pierwsze różnice zamiast poziomów
  - nic (Sims et al. 1990) - interesują nas zależności między zmiennymi, a nie parametry
- Najczęstsza (i najbezpieczniejsza praktyka): dodać trend deterministyczny

- Autokorelacja:
  - estymator MNK jest obciążony
  - oznaka złej specyfikacji modelu VAR (zbyt niski rząd opóźnień)
- Podstawowe testy:
  - Ljung-Box
  - Breusch-Godfrey

- Test ilorazu wiarygodności: test istotności kolejnych opóźnień wszystkich zmiennych w poszczególnych równaniach.
  - $H_0$  : zasadność nałożonych restrykcji
- Idea: porównać funkcję wiarygodności modelu z restrykcjami (mniejsza liczba opóźnień) i bez (większa liczba opóźnień).

$$y_t = A_0 + A_1 y_{t-1} + A_2 y_{t-2} + \dots A_p y_{t-p} + \epsilon_t$$

czyli

$$E_T [y_{T+1}] = A_0 + A_1 y_T + A_2 y_{T-1} + \dots A_p y_{T-p+1}$$

$$E_T [y_{T+2}] = A_0 + A_1 E_T [y_{T+1}] + A_2 y_T + \dots A_p y_{T-p+2}$$

i tak dalej.

# Prognozowanie z modelem VAR

- Stacjonarny proces VAR można zapisać w postaci wektorowej średniej ruchomej (VMA)

$$y_t = \mu + \sum_{i=0}^{\infty} \Theta_i \epsilon_{t-i}$$

czyli

$$y_{T+1} - E_T[y_{T+1}] = \epsilon_{T+1}$$

$$y_{T+2} - E_T[y_{T+2}] = \epsilon_{T+2} + \Theta_1 \epsilon_{T+1}$$

i tak dalej.

- Wariancja prognozy na  $k$  okresów

$$\text{Var}[y_{T+k} - E_T[y_{T+k}]] = \sum_{i=0}^{k-1} \Theta_i \Sigma \Theta_i'$$

co pozwala nam zbudować przedziały ufności.

## Modele SVAR

---



- Model VAR

$$y_t = A_0 + A_1 y_{t-1} + A_2 y_{t-2} + \dots + A_p y_{t-p} + \epsilon_t$$

$$\epsilon_t \sim N(0, \Sigma)$$

- Model SVAR

$$Ay_t = C_0 + C_1 y_{t-1} + C_2 y_{t-2} + \dots + C_p y_{t-p} + B\eta_t$$

$$\eta_t \sim N(0, I)$$

- Różnica: składniki losowe w SVAR są względem siebie niezależne.  
Interpretacja: *szoki strukturalne*.

- Model SVAR

$$Ay_t = C_0 + C_1y_{t-1} + C_2y_{t-2} + \dots + C_p y_{t-p} + B\eta_t$$

$$\eta_t \sim N(0, I)$$

- Macierze  $A$  i  $B$  określają jednoczesne zależności między zmiennymi endogenicznymi, macierze  $C_p$  dynamiczne właściwości modeli.

- Parametry modelu SVAR otrzymuje się w dwóch krokach:
  1. estymacja parametrów modelu VAR
  2. strukturalizacja

- Model SVAR pozwala analizować dynamiczną reakcję na szoki strukturalne
  - “jak zmieni się inflacja za 3 kwartały, jeśli stopa procentowa zostanie teraz niespodziewanie podniesiona o 25pb?”
- Reakcja określana przez funkcję reakcji na impuls (impulse response function - IRF)

$$IRF_{k(ij)} = \frac{\partial y_{i,t+k}}{\partial \eta_{jt}}$$

- IRF można otrzymać przez przekształcenie modelu do postaci SVMA( $\infty$ ):

$$y_t = \mu + \sum_{k=0}^{\infty} \psi_k \eta_{t-k}$$

gdzie  $\psi_k = IRF_k$ .

# Funkcja reakcji na impuls

- Aby otrzymać IRF:
  - Zapisać model SVAR w postaci zredukowanej (VAR):

$$y_t = A^{-1}C_0 + A^{-1}C_1y_{t-1} + A^{-1}C_2y_{t-2} + \dots + A^{-1}C_p y_{t-p} + A^{-1}B\eta_t$$

czyli  $\epsilon_t \equiv A^{-1}B\eta_t$ .

- Zapisać model VAR w postaci VMA( $\infty$ )

$$y_t = \mu + \epsilon_t + \sum_{i=1}^{\infty} \Theta_i \epsilon_{t-i}$$

- Ponieważ  $\epsilon_t = A^{-1}B\eta_t$ , IRF otrzymujemy jako

$$\Psi_i = \Theta_i A^{-1}B$$

- Niekiedy pracujemy na zmiennych typu  $\Delta PKB_t$ , a interesuje nas reakcja  $PKB_t$ , nie pierwszej różnicy.
- Możemy otrzymać skumulowany IRF:

$$AIRF_{k(ij)} = \frac{\partial z_{i,t+k}}{\partial \eta_{jt}} = \sum_{m=0}^k IRF_{k(ij)}$$

- Wariancja błędu losowego prognozy dla  $y_t$  dla  $k$  okresów do przodu to

$$\Sigma_k = \text{Var} \left( y_{T+k} - y_{T+k}^f \right) = \sum_{m=0}^{k-1} \Psi_m \Psi_m'$$

- Dla  $y_{it}$  na  $k$  okresów do przodu to

$$\Sigma_{k(ii)} = \sum_{j=1}^N \left( \Psi_{0(ii)}^2 + \Psi_{1(ii)}^2 + \dots + \Psi_{k-1(ii)}^2 \right)$$

- FEVD (*forecast error variance decomposition*) określa jaka część  $\Sigma_{k(ii)}$  wynika z poszczególnych szoków strukturalnych

$$FEVD_{k(ii)} = \frac{\Psi_{0(ii)}^2 + \Psi_{1(ii)}^2 + \dots + \Psi_{k-1(ii)}^2}{\Sigma_{k(ii)}}$$



- Dla  $k \rightarrow \infty$  FEVD można interpretować jako dekompozycję wariancji na zmiennych endogenicznych modelu VAR.
  - “21% zmienności inflacji można tłumaczyć szokami podażowymi, 12 szokami polityki pieniężnej...”

- Jak otrzymać parametry modelu SVAR z parametrów modelu VAR?
- Model VAR

$$y_t = A_0 + A_1 y_{t-1} + A_2 y_{t-2} + \dots + A_p y_{t-p} + \epsilon_t$$
$$\epsilon_t \sim N(0, \Sigma)$$

łącznie  $K_{VAR} = PN^2 + N + \frac{N(N+1)}{2}$  parametrów

- Model SVAR

$$Ay_t = C_0 + C_1 y_{t-1} + C_2 y_{t-2} + \dots + C_p y_{t-p} + B\eta_t$$
$$\eta_t \sim N(0, I)$$

łącznie  $K_{SVAR} = N^2 + PN^2 + N + N^2$  parametrów

- Potrzeba  $K$  dodatkowych restrykcji

$$\begin{aligned} K &= K_{SVAR} - K_{VAR} \\ &= N^2 + \frac{N(N-1)}{2} \end{aligned}$$

- Decyzja zależy od badacza, różne możliwe restrykcje:
  - strukturalizacja krótkookresowa (np. szok stopy procentowej wpływa na pewne zmienne z opóźnieniem)
  - strukturalizacja długookresowa (w długim okresie neutralność pieniądza)
  - *sign restrictions* (dodatni szok stopy procentowej zwiększa koszt kredytu dla firm)
  - ...

- VAR(1)

$$y_t = A_1 y_{t-1} + \epsilon_t$$

- SVAR(1)

$$A y_t = C_1 y_{t-1} + B \eta_t$$

- $N = 2$ , więc potrzeba 5 restrykcji. Możemy wybrać:

$$A = \begin{bmatrix} 1 & 0 \\ * & 1 \end{bmatrix} \qquad B = \begin{bmatrix} * & 0 \\ 0 & * \end{bmatrix}$$

- Powyższy przykład to *rekursywna* strukturalizacja krótkookresowa

$$A = \begin{bmatrix} 1 & 0 & \dots & 0 \\ * & 1 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ * & * & \dots & 1 \end{bmatrix} \quad B = \begin{bmatrix} * & 0 & \dots & 0 \\ 0 & * & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & * \end{bmatrix}$$

- Parametry można wyznaczyć rozwiązując układ równań

$$\Sigma = A^{-1}BB' (A^{-1})'$$

- Dekompozycja Cholesky'ego