

Modele wektorowej autoregresji

ASC 2023

Piotr Żoch

- Model VAR
- Budowa i analiza modelu VAR
- Prognozowanie za pomocą modelu VAR
- Modele SVAR

Modele VAR

- VAR: **v**ector **a**utoregression
- uwzględnia powiązania między zmiennymi ekonomicznymi
- pomocny w opisie dynamicznych właściwości zmiennej wielowymiarowej
- przy dodatkowych założeniach - model ekonomiczny (structural VAR - SVAR)

- Modele VAR powstały w późnych latach 70. w odpowiedzi na problemy dużych modeli strukturalnych:
 - podział na zmienne endo- i egzogeniczne a priori
 - wybór struktury dynamicznej modelu a priori
 - niska jakość prognoz
 - problemy z identyfikacją

- Sims (1980), modele VAR przydatne w:
 - prognozowaniu szeregów czasowych
 - projektowaniu i ewaluacji modeli ekonomicznych
 - ocenie efektów alternatywnych polityk (jeśli nie różnią się zbytnio od obecnych)

- Niech y_t będzie wektorem $y_t = (y_{1,t}, y_{2,t}, \dots, y_{n,t})'$. Model VAR to

$$y_t = A_0 + A_1 y_{t-1} + A_2 y_{t-2} + \dots + A_p y_{t-p} + \epsilon_t$$

gdzie $\epsilon_t \sim N(0, \Sigma)$.

- A_0 to wektor $n \times 1$, A_1, \dots, A_p oraz Σ to macierze o wymiarach $n \times n$.
- Można też dodać zmienne deterministyczne, np. trend, zmienne 0/1, zmienne sezonowe i tym podobne.

- Model VAR można też przedstawić za pomocą wielomianu opóźnień jako

$$(I - A_1L - \dots - A_pL^p)y_t = A_0 + \epsilon_t$$

czyli

$$A(L)y_t = A_0 + \epsilon_t.$$

- Brak podziału a priori na zmienne endo- i egzogeniczne
- Ateoretyczność (teoria służy do wybrania zmiennych, nie do modelowania zależności między nimi)
- Zwykle bardzo dobre prognozy w krótkim okresie
- Parametry modelu *nie* podlegają interpretacji, zamiast tego interesuje nas np. funkcja reakcji na impuls

- Dwie decyzje przy budowie modelu VAR:
 - jakie zmienne uwzględnić (+ zmienne deterministyczne)
 - jaki rząd opóźnień wybrać

- Kryteria:
 - kryteria informacyjne (AIC, BIC, HQIC)
 - dopasowanie do danych vs. liczba oszacowanych parametrów
 - brak autokorelacji składnika losowego
 - test istotności opóźnień

- W przypadku modelu AR(p) mieliśmy

$$(1 - a_1L - a_2L^2 - \dots - a_pL^p) y_t = a_0 + \epsilon_t$$

$$A(L) y_t = a_0 + \epsilon_t$$

- Model AR(p) jest **stacjonarny** tylko dla wartości parametrów a_1, \dots, a_p , dla których pierwiastki równania $A(x)$ spełniają $|x_p| > 1$ dla każdego p
- Analogicznie jest w przypadku modelu VAR(p)

- Jeśli $\lim_{k \rightarrow \infty} \frac{\partial y_{t+k}}{\partial \epsilon_t} = 0$ to model VAR jest *stacjonarny*
 - wpływ szoku w okresie t wygasa w przyszłości
 - istnieje poziom μ , do którego proces powraca
 - tempo powrotu dane przez pierwiastki równania

$$|A(z)| = 0$$

- jeśli pierwiastki są poza kołem jednostkowym - stacjonarność

- Przykład: VAR(1)

$$y_t = A_1 y_{t-1} + \epsilon_t$$
$$\underbrace{(I - A_1 L)}_{=A} y_t = \epsilon_t$$

czyli

$$A = \begin{bmatrix} 1 - a_{11}L & -a_{12}L \\ -a_{21}L & 1 - a_{22}L \end{bmatrix}$$

i

$$|A(z)| = (1 - a_{11}z)(1 - a_{22}z) - a_{11}a_{21}z^2$$

- Przykład: VAR(1). Niech $a_{11} = a_{22} = \rho$ a $a_{12} = a_{21} = 0$.

$$|A(z)| = (1 - \rho z)(1 - \rho z)$$

więc $z = \rho^{-1}$ a zatem pierwiastki będą poza kołem jednostkowym dla $-1 < \rho < 1$.

VAR - stacjonarność

- Co w przypadku VAR(p), gdzie $p > 1$?
- Każdy VAR(p) można przekształcić do VAR(1) (*postać kanoniczna*)
- Przykład: AR(2)

$$y_{1,t} = \rho_1 y_{1,t-1} + \rho_2 y_{1,t-2} + \epsilon_t$$

Zdefiniujmy $y_{2,t} = y_{1,t-1}$. Mamy układ równań

$$y_{1,t} = \rho_1 y_{1,t-1} + \rho_2 y_{2,t-1} + \epsilon_t$$

$$y_{2,t} = y_{1,t-1}$$

czyli

$$y_t = \underbrace{\begin{bmatrix} \rho_1 & \rho_2 \\ 1 & 0 \end{bmatrix}}_{A_1} y_{t-1} + \begin{bmatrix} 1 \\ 0 \end{bmatrix} \epsilon_t$$

- Dla VAR(1)

$$|A(z)| = |I - A_1 z|$$

więc jeśli mamy z, że $|I - A_1 z| = 0$ to

$$|I \frac{1}{z} - A_1| = 0$$

czyli

$$|A_1 - I \underbrace{\lambda}_{=\frac{1}{z}}| = 0$$

- VAR(1) jest stacjonarny, jeśli wszystkie pierwiastki λ równania

$$|A_1 - I\lambda| = 0$$

leżą w kole jednostkowym.

- λ to wartości własne macierzy A_1
- Uwaga: łatwo się pomylić czy pierwiastki/wartości własne mają być w czy *poza* kołem jednostkowym (podobnie jak w przypadku modeli AR)

- Estymacja: można zastosować metodę najmniejszych kwadratów (KMNK/OLS) dla każdego równania osobno
- Co zrobić jeśli poszczególne zmienne są niestacjonarne?
 - uwzględnić informację o kointegracji (jeśli jest) - model VECM
 - pierwsze różnice zamiast poziomów
 - nic (Sims et al. 1990) - interesują nas zależności między zmiennymi, a nie parametry
- Najczęstsza (i najbezpieczniejsza praktyka): dodać trend deterministyczny

- Autokorelacja:
 - estymator MNK jest obciążony
 - oznaka złej specyfikacji modelu VAR (zbyt niski rząd opóźnień)
- Podstawowe testy:
 - Ljung-Box
 - Breusch-Godfrey

- Test ilorazu wiarygodności: test istotności kolejnych opóźnień wszystkich zmiennych w poszczególnych równaniach.
 - H_0 : zasadność nałożonych restrykcji
- Idea: porównać funkcję wiarygodności modelu z restrykcjami (mniejsza liczba opóźnień) i bez (większa liczba opóźnień).

$$y_t = A_0 + A_1 y_{t-1} + A_2 y_{t-2} + \dots A_p y_{t-p} + \epsilon_t$$

czyli

$$E_T [y_{T+1}] = A_0 + A_1 y_T + A_2 y_{T-1} + \dots A_p y_{T-p+1}$$

$$E_T [y_{T+2}] = A_0 + A_1 E_T [y_{T+1}] + A_2 y_T + \dots A_p y_{T-p+2}$$

i tak dalej.

Prognozowanie z modelem VAR

- Stacjonarny proces VAR można zapisać w postaci wektorowej średniej ruchomej (VMA)

$$y_t = \mu + \sum_{i=0}^{\infty} \Theta_i \epsilon_{t-i}$$

czyli

$$y_{T+1} - E_T[y_{T+1}] = \epsilon_{T+1}$$

$$y_{T+2} - E_T[y_{T+2}] = \epsilon_{T+2} + \Theta_1 \epsilon_{T+1}$$

i tak dalej.

- Wariancja prognozy na k okresów

$$\text{Var}[y_{T+k} - E_T[y_{T+k}]] = \sum_{i=0}^{k-1} \Theta_i \Sigma \Theta_i'$$

co pozwala nam zbudować przedziały ufności.

Modelle SVAR

- Model VAR

$$y_t = A_0 + A_1 y_{t-1} + A_2 y_{t-2} + \dots + A_p y_{t-p} + \epsilon_t$$

$$\epsilon_t \sim N(0, \Sigma)$$

- Model SVAR

$$Ay_t = C_0 + C_1 y_{t-1} + C_2 y_{t-2} + \dots + C_p y_{t-p} + B\eta_t$$

$$\eta_t \sim N(0, I)$$

- Różnica: składniki losowe w SVAR są względem siebie niezależne.
Interpretacja: *szoki strukturalne*.

- Model SVAR

$$Ay_t = C_0 + C_1y_{t-1} + C_2y_{t-2} + \dots + C_p y_{t-p} + B\eta_t$$

$$\eta_t \sim N(0, I)$$

- Macierze A i B określają jednoczesne zależności między zmiennymi endogenicznymi, macierze C_p dynamiczne właściwości modeli.

- Rozważmy prosty model SVAR

$$y_t = Cy_{t-1} + B\eta_t$$

$$\eta_t \sim N(0, I)$$

powyższą postać nazywamy *postacią strukturalną*.

- Problem: nie obserwujemy B i η_t oddzielnie (obserwujemy jedynie y_t). *Postać zredukowana*:

$$y_t = Cy_{t-1} + \epsilon_t$$

$$\epsilon_t \sim N\left(0, \underbrace{BB'}_{=\Sigma}\right)$$

- W ogólnym przypadku SVAR (postać strukturalna)

$$Ay_t = C_0 + C_1y_{t-1} + C_2y_{t-2} + \dots + C_py_{t-p} + B\eta_t$$
$$\eta_t \sim N(0, I)$$

- Postać zredukowana

$$y_t = A_0 + A_1y_{t-1} + A_2y_{t-2} + \dots + A_py_{t-p} + \epsilon_t$$
$$\epsilon_t \sim N(0, \Sigma)$$

gdzie $A_0 = A^{-1}C_0$... oraz $\epsilon_t = A^{-1}B\eta_t$ i $\Sigma = A^{-1}B(A^{-1}B)'$.

- Parametry modelu SVAR otrzymuje się w dwóch krokach:
 1. estymacja parametrów modelu VAR (postać zredukowana)
 2. strukturalizacja/identyfikacja (“przejście” z ϵ_t do η_t)

- Model SVAR pozwala analizować dynamiczną reakcję na szoki strukturalne
 - *“jak zmieni się inflacja za 3 kwartały, jeśli stopa procentowa zostanie teraz niespodziewanie podniesiona o 25pb?”*
- Reakcja określana przez funkcję reakcji na impuls (impulse response function - IRF)

$$IRF_{k(ij)} = \frac{\partial y_{i,t+k}}{\partial \eta_{jt}}$$

- IRF można otrzymać przez przekształcenie modelu do postaci SVMA(∞):

$$y_t = \mu + \sum_{k=0}^{\infty} \psi_k \eta_{t-k}$$

gdzie $\psi_k = IRF_k$.

Funkcja reakcji na impuls

- Aby otrzymać IRF:
 - Zapisać model SVAR w postaci zredukowanej (VAR):

$$y_t = A^{-1}C_0 + A^{-1}C_1y_{t-1} + A^{-1}C_2y_{t-2} + \dots + A^{-1}C_p y_{t-p} + A^{-1}B\eta_t$$

czyli $\epsilon_t \equiv A^{-1}B\eta_t$.

- Zapisać model VAR w postaci VMA(∞)

$$y_t = \mu + \epsilon_t + \sum_{i=1}^{\infty} \Theta_i \epsilon_{t-i}$$

- Ponieważ $\epsilon_t = A^{-1}B\eta_t$, IRF otrzymujemy jako

$$\Psi_i = \Theta_i A^{-1}B$$

- Niekiedy pracujemy na zmiennych typu ΔPKB_t , a interesuje nas reakcja PKB_t , nie pierwszej różnicy.
- Możemy otrzymać skumulowany IRF:

$$AIRF_{k(ij)} = \frac{\partial z_{i,t+k}}{\partial \eta_{jt}} = \sum_{m=0}^k IRF_{k(ij)}$$

- Wariancja błędu losowego prognozy dla y_t dla k okresów do przodu to

$$\Sigma_k = \text{Var} \left(y_{T+k} - y_{T+k}^f \right) = \sum_{m=0}^{k-1} \Psi_m \Psi_m'$$

- Dla y_{it} na k okresów do przodu to

$$\Sigma_{k(ii)} = \sum_{j=1}^N \left(\Psi_{0(ii)}^2 + \Psi_{1(ii)}^2 + \dots + \Psi_{k-1(ii)}^2 \right)$$

- FEVD (*forecast error variance decomposition*) określa jaka część $\Sigma_{k(ii)}$ wynika z poszczególnych szoków strukturalnych

$$FEVD_{k(ii)} = \frac{\Psi_{0(ii)}^2 + \Psi_{1(ii)}^2 + \dots + \Psi_{k-1(ii)}^2}{\Sigma_{k(ii)}}$$

- Dla $k \rightarrow \infty$ FEVD można interpretować jako dekompozycję wariancji na zmiennych endogenicznych modelu VAR.
 - “21% zmienności inflacji można tłumaczyć szokami podażowymi, 12 szokami polityki pieniężnej...”

- Jak otrzymać parametry modelu SVAR z parametrów modelu VAR?
- Model VAR

$$y_t = A_0 + A_1 y_{t-1} + A_2 y_{t-2} + \dots + A_p y_{t-p} + \epsilon_t$$
$$\epsilon_t \sim N(0, \Sigma)$$

łącznie $K_{VAR} = PN^2 + N + \frac{N(N+1)}{2}$ parametrów

- Model SVAR

$$Ay_t = C_0 + C_1 y_{t-1} + C_2 y_{t-2} + \dots + C_p y_{t-p} + B\eta_t$$
$$\eta_t \sim N(0, I)$$

łącznie $K_{SVAR} = N^2 + PN^2 + N + N^2$ parametrów

- Potrzeba K dodatkowych restrykcji

$$\begin{aligned} K &= K_{SVAR} - K_{VAR} \\ &= N^2 + \frac{N(N-1)}{2} \end{aligned}$$

- Decyzja zależy od badacza, różne możliwe restrykcje:
 - strukturalizacja krótkookresowa (np. szok stopy procentowej wpływa na pewne zmienne z opóźnieniem)
 - strukturalizacja długookresowa (np. w długim okresie neutralność pieniądza)
 - *sign restrictions* (np. dodatni szok stopy procentowej zwiększa koszt kredytu dla firm)
 - ...
- Przyjmijmy od teraz, że $A = I$.

- Rozważmy prosty przykład: niech y_t to PKB a r_t to stopa procentowa. Postać strukturalna:

$$\begin{bmatrix} y_t \\ r_t \end{bmatrix} = \begin{bmatrix} c_{11} & c_{12} \\ c_{21} & c_{22} \end{bmatrix} \begin{bmatrix} y_{t-1} \\ r_{t-1} \end{bmatrix} + \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix} \begin{bmatrix} \overbrace{\eta_t^y}^{\text{szok popytowy}} \\ \underbrace{\eta_t^r}_{\text{szok polityki pieniężnej}} \end{bmatrix}$$

Postać zredukowana:

$$\begin{bmatrix} y_t \\ r_t \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} \begin{bmatrix} y_{t-1} \\ r_{t-1} \end{bmatrix} + \begin{bmatrix} \epsilon_{1t} \\ \epsilon_{2t} \end{bmatrix}$$

- Pytanie badawcze: *jaki jest wpływ szoku polityki pieniężnej na PKB?*
- Nie możemy po prostu znaleźć funkcji reakcji na impuls ϵ_{2t} bo

$$\epsilon_{2t} = b_{21}\eta_t^y + b_{22}\eta_t^r$$

- Czym jest ϵ_{2t} ?

$$\epsilon_{2t} = b_{21}\eta_t^y + b_{22}\eta_t^r$$

więc może to być zarówno szok polityki pieniężnej (przez b_{22}), jak i odpowiedź polityki pieniężnej na szok popytowy (przez b_{21}).

- Problem identyfikacji polega na znalezieniu takiej macierzy B , że

$$\epsilon_t = B\eta_t$$

- Możemy w tym celu wykorzystać zależność, że

$$\Sigma = E [\epsilon_t \epsilon_t'] = BB'$$

- Problem: jest nieskończenie wiele macierzy $\tilde{B} = BZ$, gdzie $ZZ' = I$, które są rozwiązaniem.
- Intuicyjnie: Σ jest symetryczną macierzą, przez co mamy mniej równań, niż niewiadomych.
- Skąd wziąć brakujące równania?

- W naszym prostym przykładzie:

$$\sigma_1^2 = b_{11}^2 + b_{12}^2$$

$$\sigma_{12} = b_{11}b_{12} + b_{12}b_{22}$$

$$\sigma_{21} = b_{11}b_{12} + b_{12}b_{22}$$

$$\sigma_2^2 = b_{21}^2 + b_{22}^2$$

czyli 3 równania i 4 niewiadome.

- Przyjmimy, że polityka pieniężna działa na PKB z opóźnieniem (dlaczego?).
- To oznacza, że

$$\epsilon_{1t} = b_{11}\eta_t^y + \underbrace{b_{12}}_{=0}\eta_t^r,$$

czyli $b_{12} = 0$. Mamy układ równań

$$\begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ - & \sigma_2^2 \end{bmatrix} = \begin{bmatrix} b_{11} & 0 \\ b_{21} & b_{22} \end{bmatrix} \begin{bmatrix} b_{11} & b_{21} \\ 0 & b_{22} \end{bmatrix}$$

- Rozwiązanie:

$$b_{11} = \sigma_1$$

$$b_{21} = \frac{\sigma_{12}}{\sigma_1}$$

$$b_{22} = \sqrt{\sigma_2^2 - \frac{\sigma_{12}^4}{\sigma_1^2}}$$

- To pozwala nam wyznaczyć efekt szoku polityki pieniężnej $\eta_t^r = 1$ jako

$$y_t = 0$$

$$r_t = \sqrt{\sigma_2^2 - \frac{\sigma_{12}^4}{\sigma_1^2}}$$

w bieżącym okresie. Resztę funkcji reakcji na impuls otrzymujemy w standardowy sposób.

- Powyższy przykład to *rekursywna* strukturalizacja krótkookresowa (Sims, 1980).

$$B = \begin{bmatrix} * & 0 & \dots & 0 \\ * & * & \dots & 0 \\ \dots & \dots & \dots & \dots \\ * & * & \dots & * \end{bmatrix}$$

Idea bazuje na tym, że pewne zmienne działają na inne z opóźnieniem.

- Parametry można wyznaczyć rozwiązując układ równań

$$\Sigma = BB'$$

- Dekompozycja Cholesky'ego.